



УНИВЕРЗИТЕТ У НИШУ
ЕЛЕКТРОНСКИ ФАКУЛТЕТ
Катедра за рачунарство



Екстракција именованих ентитета у текстовима на српском језику

Самостални истраживачки рад

Студијски програм: рачунарство и информатика

Модул: софтверско инжењерство

Студент:

Ненад Павловић, бр. инд. 1796


Ментор:

Проф. др Милош Богдановић

Ниш, септембар 2026. година

Сажетак

У овом раду обрађује се препознавање именованих ентитета (енгл. Named Entity Recognition, NER) у текстовима на српском језику, са фокусом на домен легислативе (закони и прописи). За разлику од приступа који се ослањају на фино подешавање (енгл. fine-tuning) модела, овде се испитује могућност примене савремених великих језичких модела (енгл. Large Language Models, LLM) искључиво кроз промптовање. Креиран је наменски аотиран скуп података из српске легислативе са осам типова правних ентитета, а затим је извршено поређење модела фамилије Qwen3 у две варијанте — „инструкцијска“ (енгл. instruction) и „мислећа“ (енгл. thinking) — и то у две димензије (4B и 30B параметара). Као референтни модел коришћен је фино подешени модел NER4Legal_SRB. Резултати указују на три главна налаза: промптовање без fine-tuning-a даје ограничен учинак; „мислећа“ варијанта помера модел ка високој прецизности и ниском одзиву; а специјализовани модел значајно губи тачност при промени домена.




Слика 1: Пример NER-a

Садржај

Сажетак	2
Садржај	3
1. Увод	1
2. Теоријска основа.....	2
2.1. Препознавање именованих ентитета.....	2
2.2. Трансформер архитектура и BERT.....	2
2.3. Језички модели за српски језик.....	3
2.4. Генеративни језички модели: „инструкцијски" и „мислећи"	4
2.5. Promptовање: zero-shot, few-shot i lanac rasuđivanja	5
3. Преглед сличних истраживања	5
4. Корпуси и ресурси за српски NER.....	6
5. Методологија	7
5.1. Креирање скупа података.....	7
5.2. Shema анотације	8
5.3. Одабир модела.....	8
5.4. Поставка експеримента.....	9
5.5. Евалуциона метрика.....	9
6. Резултати	10
7. Дискусија резултата	12
8. Ограничења	13
9. Закључак.....	14
10. Литература	15

1. Увод

У овом раду обрађује се препознавање именованих ентитета (енгл. Named Entity Recognition, NER) у текстовима на српском језику, са фокусом на домен легислативе (закони и прописи). За разлику од приступа који се ослањају на фино подешавање (енгл. fine-tuning) модела, испитује се могућност примене савремених великих језичких модела (енгл. Large Language Models, LLM) искључиво путем promptinga. Креиран је наменски аотиран скуп података из српске легислативе са осам типова правних ентитета, а затим је извршено поређење модела из фамилије Qwen3 у две варијанте — „инструкцијској“ (енгл. instruction) и „мислећој“ (енгл. thinking) — и то у две димензије, са 4B и 30B параметара. Као референтни модел коришћен је фино подешени модел NER4Legal_SRB. Резултати указују на три главна налаза: prompting без fine-tuning-a даје ограничен учинак; „мислећа“ варијанта помера модел ка високој прецизности и ниском одзиву; а специјализовани модел значајно губи тачност при промени домена.



Слика 2: NER-LLM

2. Теоријска основа

2.1. Препознавање именованих ентитета

Препознавање именованих ентитета дефинише се као задатак означавања низа токена, у којем се сваком токену додељује ознака која указује на то да ли он припада неком ентитету и ком типу. Углавном се користи IOB2 (или BIO) шема, у којој ознака „B-“ означава почетак ентитета, „I-“ наставак ентитета, а „O“ токен који не припада ниједном ентитету [12]. Традиционалне скупове типова чине особе (PER), локације (LOC), организације (ORG) и разни остали ентитети (MISC), док специјализовани домени уводе сопствене типове [6].

Историјски, приступи NER-у развијали су се од система заснованих на ручно писаним правилима и реченицама, преко класичних метода машинског учења (попут условних случајних поља), до савремених модела дубоког учења [4]. Модели дубоког учења данас представљају стандард јер аутоматски уче репрезентације језика из великих количина текста, без потребе за ручним инжењерингом обележја [2].

Препознавање именованих ентитета примењује се у резлиштим системима: у претрази и индексирању докумената, у системима за одговарање на питања, у изградњи графова знања, у заштити личних и осетљивих података и у екстракцији структурисаних информација из неструктурисаних текстова [2]. У правном домену, поуздано издвајање ентитета попут назива прописа, датума ступања на снагу, новчаних износа и назива судова чини основу за аутоматско повезивање, класификацију и претрагу аката [6].

Упркос привидној једноставности, задатак носи неколико изазова. Границе ентитета често су вишезначне, нарочито код вишечланих назива; исти низ речи може, зависно од контекста, припадати различитим типовима; а поједини ентитети могу бити угњеждени један унутар другог [6]. Специјализовани домени, попут правног, уводе сопствене типове ентитета којих нема у општим корпусима, док за нискоресурсне језике попут српског недостатак великих аотираних корпуса додатно ограничава квалитет надгледаних приступа [4]. Због тога се квалитет NER система мери одвојено по типовима ентитета, а не само укупно.

2.2. Трансформер архитектура и BERT

Велики напредак у обради природног језика представља transformer архитектура, заснована на механизму пажње (енгл. attention), која омогућава моделирање зависности између речи независно од њихове удаљености у реченици и ефикасно паралелно тренирање [1]. На овој архитектури изграђени су модели који су поставили нове стандарде на широком спектру задатака.

Модел BERT (енгл. Bidirectional Encoder Representations from Transformers) увео је парадигму предтренирања дубоких двосмерних репрезентација над великим неанотираним корпусима, уз накнадно фино подешавање на конкретном задатку [2]. За задатак NER-а, над енкодерским моделом се додаје слој за класификацију токена, који се потом фино подешава на аотираном корпусу. Сродна архитектура ELECTRA уводи ефикаснији начин предтренирања у којем се модел учи да разликује замењене токене, постижући боље резултате уз мање рачунарских ресурса [3].

Суштина transformer-a је механизам самопажње (енгл. self-attention), који за сваку реч рачуна тежинску комбинацију репрезентација свих осталих речи у реченици, омогућавајући моделу да динамички одреди које су речи међусобно релевантне [1].

Употребом више „глава“ пажње (енгл. multi-head attention) модел истовремено моделира различите врсте односа, док се редослед речи кодира посебним позиционим кодирањем, будући да механизам пажње сам по себи не разликује поредак [1]. Ове особине чине transformer нарочито погодним за језичко моделирање на великој скали.

Модел BERT предтренира се са два циља: моделирањем маскираног језика (енгл. masked language modeling), где се насумично сакривени токени предвиђају из контекста, и предвиђањем следеће реченице [2]. Тиме модел учи дубоке двосмерне репрезентације, које се затим, уз додатак лаког излазног слоја, фино подешавају за конкретан задатак. Улазни текст се претходно дели на подречи (енгл. subword tokens) поступцима попут WordPiece или BPE, чиме се ограничава величина речника и омогућава обрада непознатих речи — што је значајно за морфолошки богате језике какав је српски [2]. За NER, ова подела на подречи захтева пажљиво мапирање предикција назад на ниво речи.

2.3. Језички модели за српски језик

За српски и сродне јужнословенске језике развијено је неколико модела. Најистакнутији је BERTiћ, transformer модел заснован на ELECTRA архитектури, предтрениран на преко осам милијарди токена веб текста на босанском, хрватском, црногорском и српском језику (BCMS) [4]. У својој основној величини има око 110 милиона параметара и на задатку NER-a надмашује вишејезичне моделе на већини испитиваних корпуса [4].

Поред BERTiћа, истраживачка заједница окупљена око Друштва за језичке ресурсе и технологије развила је серију модела Jerteh (нпр. jerteh-355 са 355 милиона и jerteh-81 са 81 милионом параметара), као и модел SrBERTa, који је додатно прилагођен правном домену [5]. Упоредна анализа десет модела за српски показала је да на задатку NER-a најбоље резултате постижу модели BERTiћ и xlm-r-bertic (F1 мере око 0,94), при чему је уочено да величина модела има тек благ позитиван утицај на учинак, док величина и квалитет тренинг корпуса имају израженији ефекат [5].

Пре појаве наменских модела, српски се обрађивао вишејезичним моделима попут mBERT-a и XLM-RoBERTa, као и регионалним моделом CroSloEngual BERT [4]. Њихова предност је покривеност многих језика, али по правилу заостају за моделима предтренираним искључиво на циљаном језику или ужој групи сродних језика, јер расположиви капацитет деле на стотине језика [4]. Управо зато BERTiћ, трениран само на BCMS простору, постиже боље резултате на већини задатака за српски.

Модел	Параметри	NER F1
classla/bcms-bertic (BERTić)	110 M	0,942
classla/xlm-r-bertic	561 M	0,942
xlm-roberta-large	561 M	0,935
xlm-roberta-base	279 M	0,933
jerteh-355	355 M	0,928
jerteh-81	81 M	0,928
SRoBERTa-base	120 M	0,908

Табела 1. F1 мера на NER-у за српски (корпус SrpELTeC-gold) и број параметара [5].

Из Табеле 1 уочава се да најбољи резултат постижу модели са највећим или најквалитетнијим тренинг корпусом, док разлика између модела од 81 и 355 милиона параметара практично не постоји — потврда да величина модела има ограничен утицај на квалитет NER-а код енкодерских модела [5].

2.4. Генеративни језички модели: „инструкцијски" и „мислећи"

За разлику од енкодерских модела попут BERT-а, генеративни (декодерски) велики језички модели генеришу текст и могу се навести на различите задатке без промене параметара, само кроз одговарајуће инструкције [9]. Савремени генеративни модели пролазе кроз фазу инструкцијског подешавања (енгл. *instruction tuning*), која их чини способним да прате захтеве задате природним језиком.

Новија генерација модела уводи и такозване „мислеће“ (енгл. *thinking*, односно *reasoning*) варијанте, које пре давања коначног одговора генеришу експлицитан ланац расуђивања [10]. Фамилија модела Qwen3 компаније Alibaba испоручује се у засебним „инструкцијским“ и „мислећим“ варијантама и у више величина, што је чини погодном за систематско поређење утицаја врсте и димензије модела [11]. Емпиријски налази, међутим, показују да инструкцијско подешавање и експлицитно расуђивање не побољшавају учинак на свим задацима подједнако [8].

Инструкцијско подешавање спроводи се додатним тренирањем предтренираног модела на скупу парова инструкција–одговор, често праћеним учењем из људских повратних информација (енгл. *reinforcement learning from human feedback*), чиме модел постаје способан да прати захтеве и производи корисне одговоре [9]. Овакви модели могу се применити на нов задатак без икаквог додатног тренирања, што их чини привлачним за нискоресурсне сценарије у којима недостају анотирани подаци.

Најновија истраживања померају део рачунања са фазе тренирања на фазу закључивања (енгл. *test-time compute*): „мислећи“ модели, попут фамилија које генеришу експлицитан ланац расуђивања пре одговора, троше додатне токене на интерно размишљање како би побољшали решавање сложених проблема [10]. Неки произвођачи нуде хибридне моделе са могућношћу укључивања и искључивања размишљања, док други испоручују засебне инструкцијске и „мислеће“ варијанте; овај приступ омогућава чистије поређење јер су обе варијанте посебно оптимизоване [11]. Треба нагласити да експлицитно

расуђивање значајно повећава време и цену давања резултата, што је битно ограничење у пракси [8].

2.5. Promptovanje: zero-shot, few-shot i lanac rasuđivanja

Promptovanje подразумева формулисање улаза тако да модел произведе жељени излаз. У режиму без примера (енгл. zero-shot) моделу се даје само опис задатка, док се у режиму са неколико примера (енгл. few-shot) у сам prompt укључује мали број решених примера из којих модел учи образац путем учења у контексту (енгл. in-context learning) [9]. Показано је да укључивање примера значајно побољшава учинак на многим задацима, без икаквог мењања параметара модела [9].ж

Техника ланца расуђивања (енгл. chain-of-thought) подстиче модел да проблем решава корак по корак, што побољшава резултате на задацима који захтевају вишестепено закључивање [10]. „Мислеће“ варијанте модела ову технику имају уграђену у сам процес генерисања. За задатке попут NER-а, који захтевају прецизно одређивање граница ентитета, отворено је питање да ли експлицитно расуђивање доноси корист или уводи додатну несигурност.

Формулација prompt-а битно утиче на квалитет излаза, па се развила пракса инжењеринга prompt-а (енгл. prompt engineering): јасно дефинисање задатка, набрајање дозвољених категорија, експлицитно навођење шта се не сме означавати и захтевање одговора у структурисаном облику (на пример, као JSON) [9]. За задатке екстракције, структурисани излаз олакшава аутоматску обраду одговора, али истовремено зависи од способности модела да доследно поштује тражени формат.

Ипак, promptovanje има и ограничења: модели могу „халуцинирати“ непостојеће ентитете или измишљати ознаке ван задате шеме, могу одступати од траженог формата, а њихови излази су мање предвидљиви него код надгледаних модела [8]. За прецизне задатке попут NER-а, у којима се тражи тачно одређивање граница и доследност ознака, ова непредвидљивост може представљати значајан извор грешака, што овај рад и емпиријски испитује.

3. Преглед сличних истраживања

Најдиректније релевантно истраживање за српски језик јесте рад који под називом „From Zero to Hero“ пореди четири парадигме препознавања именованих ентитета: систем заснован на правилима, конволутивну неуронску мрежу, фино подешене трансформере и велике језичке моделе примењене кроз promptovanje [7]. Закључак тог истраживања јесте да фино подешени трансформери постижу најбоље резултате (F1 мере од 0,78 на новинским текстовима до 0,96 на узорку из уџбеника), надмашујући приступ заснован на promptovanju [7]. Овај налаз представља полазну хипотезу и за наше истраживање.

У домену српске легислативе, кључни допринос дају Калушев и Бркљач, који су развили наменски аотиран скуп података из судских пресуда и фино подесили модел BERTić, постигавши просечну F1 меру од 0,96 [6]. Њихова шема обухвата осам типова правних ентитета, коју у овом раду преузимамо. Треба нагласити да је њихов модел трениран на пресудама, док се у овом раду примењује на текстовима закона, чиме се испитује и отпорност на промену домена.

Истраживање о класификацији текста за јужнословенске језике показује да велики језички модели у zero-shot режиму често достижу или надмашују finely подешене моделе на задацима класификације, али уз мање предвидљиве излазе, спорију инференцију и веће рачунарске трошкове [8]. Аутори закључују да за обимно аутоматско означавање finely подешени модели остају практичнији избор [8]. Битно је истаћи да се тај налаз односи на класификацију, а не на NER, који је захтевнији задатак.

Препознавање ентитета у правном домену активно се истражује и за друге језике. За енглески и индијски правни систем развијени су наменски корпуси и модели за судске одлуке, док је за немачки језик показано да finely подешени BERT модели постижу високе резултате на аотираним скуповима судских пресуда. Заједничка поука ових истраживања јесте да правни текст захтева сопствене типове ентитета и да модели тренирани на једном жанру или јурисдикцији не морају добро да се пренесу на други — што је феномен познат као пад услед промене домена [6]. Овај рад управо испитује такав сценарио на српском језику, применом модела тренираног на пресудама на текстове закона.

4. Корпуси и ресурси за српски NER

У оквиру истраживања проучени су јавно доступни аотирани корпуси за српски језик. Референтни корпус стандардног српског језика јесте SETimes.SR, изведен из новинског паралелног корпуса и аотиран именованим ентитетима према IOB2 стандарду; његова верзија 2.0 садржи 176 текстова, 4.384 реченице и 97.673 токена, и објављена је под отвореном лиценцом Creative Commons Attribution-ShareAlike 4.0 [12]. За нестандардни језик доступан је корпус ReLDI-NormTagNER-sr, састављен од објава са друштвене мреже, са 3.748 текстова и 92.271 токеном [13].

Као референтни корпус за шири BCMS простор користи се hr500k, један од највећих ручно аотираних корпуса са 499.635 токена [14]. За српски постоји и књижевни корпус SrpELTeC-gold, аотиран са седам типова ентитета и величине око 330.000 токена [15]. Вишејезични корпус WikiANN (познат и као PAN-X), аутоматски изведен из Википедије, обухвата и српски језик, али са аотацијама нижег квалитета (тзв. сребрни стандард) [16].

За правни домен кључан је ресурс NER4Legal_SRB, који обухвата finely подешени модел и схему од осам типова ентитета [6]. Током овог истраживања утврђено је да је јавно објављен само модел, док сам аотирани скуп података није јавно доступан, што је условило одлуку о креирању сопственог скупа. Правни текстови у Републици Србији, према Закону о ауторском и сродним правима, не уживају ауторскоправну заштиту (закони, прописи и службени материјали изузети су из заштите), те се слободно могу користити, обрађивати и објављивати [21]. Као извор текста коришћен је званични Правно-информациони систем Републике Србије [22].

Корпус	Домен	Величина	Лиценца
SETimes.SR [12]	новински	97.673 токена	CC BY-SA 4.0
ReLDI-sr [13]	Twitter	92.271 токена	CC BY-SA 4.0
hr500k [14]	мешовити (хрв.)	499.635 токена	CC BY-SA 4.0
SrpELTeC-gold [15]	књижевни	~330.000 токена	CC BY-SA 4.0
WikiANN/PAN-X [16]	Википедија	~40.000 примера	нејасна
NER4Legal_SRB [6]	правни (пресуде)	2.172 реченице	само модел

Табела 2.Преглед јавних корпуса за српски NER.

5. Методологија

5.1. Креирање скупа података

Обзиром да аотирани скуп из правног домена није јавно доступан, креиран је наменски скуп података из српске легислативе. Прикупљено је пет обимних прописа (Кривични законик, Закон о облигационим односима, Закон о раду, Устав Републике Србије и Закон о привредним друштвима), у форматима PDF и DOCX. Текст је аутоматски очишћен (уклањање ознака чланова, фуснота и водених жигова), урађена је конверзија са ћирилице на латиницу ради усклађивања са постојећим корпусима и сегментиран на реченице уз посебно руковање правним скраћеницама и датумима. Након спајања преломљених редова добијено је 4.134 чистих реченица, уз забележен извор сваке реченице (назив прописа, број Службеног гласника и место у документу).

Због ефикасније аотације примењено је полуаутоматско обележавање: ентитети су прво предложени комбинацијом *regular expressions* (за датуме, износе, наводе Службеног гласника, *reference* и позиве на прописе) и модела *bcms-bertic-ner* (за лица и судове), након чега је урађено ручно исправљање и утврђивање ознаке. Због избегавања пристрасности, за предобележавање намерно нису коришћени модели који се касније оцењују. Аотација је обављена у алату *Label Studio* [20], а коначни скуп обухвата 1.400 реченица са 2.527 аотираних ентитета.

Екстракција текста из изворних формата захтевала је посебну пажњу: документи у формату PDF често уносе вештачке преломе редова унутар исте реченице, па је примењено спајање редова у пасусе пре сегментације, чиме је број целих реченица сведен са почетних артефактима оптерећених ~18.000 фрагмената на 4.134 смислених реченица. Сегментација на реченице прилагођена је правном тексту, уз чување скраћеница („члан.", „ст.", „бр.") и датума како се не би погрешно преломили. Ћирилични изворни текст конвертовани су у латиницу ради доследности са референтним корпусима попут SETimes.SR [12].

Будући да је легислатива сиромашна ентитетима — само око 23% реченица садржи иједан ентитет — за евалуацију „мислећих“ модела формиран је гушћи подскуп од 452 реченице, који обухвата све реченице са ређим типовима ентитета (COURT, DATE, MONEY, DECISION, REFERENCE, PERSON) и репрезентативан узорак реченица са честим типовима и празних реченица. Тиме је обезбеђено да се ређи типови вреднују на

свим расположивим појавама, а да подскуп истовремено остане статистички упоредив са целим скупом.

5.2. Shema анотације

Преузета је схема од осам типова правних ентитета из рада Калушев и Бркљач [6], јер стандардна схема PER/LOC/ORG/MISC слабо покрива легислативу — мерењем је утврђено да свега 19% реченица садржи иједан ентитет по тој схеми, а тип PER практично не постоји. Осам типова чине: COURT (назив суда), DATE (датум), DECISION (одлука/пресуда/решење), LAW (назив или скраћеница прописа), MONEY (новчани износ), OFFICIAL_GAZETTE (навод Службеног гласника), PERSON (име лица) и REFERENCE (алфанумеричка ознака предмета или акта).

Расподела ентитета у креираном скупу одражава природу легислативе: доминирају типови LAW (1.409 појава) и OFFICIAL_GAZETTE (787), док су типови COURT (77), DECISION (71), DATE (66), REFERENCE (64) и MONEY (48) знатно ређи, а тип PERSON изузетно редак (5). Оваква неравнотежа представља реално својство домена, али и ограничење за поуздану процену ретких класа.

Тип ентитета	Број појава	Удео
LAW	1.409	55,8%
OFFICIAL_GAZETTE	787	31,1%
COURT	77	3,0%
DECISION	71	2,8%
DATE	66	2,6%
REFERENCE	64	2,5%
MONEY	48	1,9%
PERSON	5	0,2%

Табела 3. Расподела ентитета у креираном скупу (1.400 реченица, 2.527 ентитета).

5.3. Одабир модела

За језгро експеримента изабрана је фамилија Qwen3, јер се испоручује у засебним инструкцијским и „мислећим“ варијантама, чиме се омогућава чисто поређење врсте модела[11]. Коришћене су варијанте Qwen3-4B-Instruct и Qwen3-4B-Thinking, као и Qwen3-30B-A3B-Instruct и Qwen3-30B-A3B-Thinking, чиме се покривају две димензије модела (мали модел густих параметара и већи модел). Сви модели су примењени искључиво кроз promptовање, без fine-tuninga. Као референтни фино подешени модел коришћен је NER4Legal_SRB [6], а модели су покретани локално помоћу алата Ollama [18] и библиотеке Transformers [19].

У погледу техничке реализације, модели мањих димензија покретани су локално, док су већи модели и „мислеће“ варијанте извршавани на графичким процесорима у облаку (Google Colab). Мерења су показала изразиту разлику у цени времена извршавања: док је инструкцијска варијанта обрађивала реченицу за мање од секунде, „мислећа“ варијанта трошила је десетине секунди по реченици због генерисања ланца расуђивања.

Ова разлика од приближно два реда величине представља практично ограничење примене „мислећих“ модела на великим корпусима и сама по себи је релевантан налаз, сагласан са запажањима из литературе о високим трошковима инференције генеративних модела [8].

5.4. Поставка експеримента

За сваку реченицу моделу је задата инструкција да из текста издвоји искључиво ентитете задатих осам типова и да резултат врати у структурираном (JSON) облику, уз експлицитно навођење шта се не означава (функције, институције које нису суд и интерни позиви на чланове). Коришћен је режим са неколико примера (few-shot), при чему је из скупа издвојено 25 примера који покривају свих осам типова, а њих шест је укључивано у prompt. Ових 25 примера искључено је из тест скупа. Инструкцијски модели су евалуирани на целом тест скупу (1.375 реченица), док су „мислећи“ модели, због приближно стотину пута споријег извршавања, евалуирани на репрезентативном подскупу од 452 реченице који обухвата све реченице са ретким типовима ентитета.

Као илустрација, системска инструкција је од модела захтевала да из реченице издвоји искључиво ентитете задатих осам типова и врати их као JSON низ, уз експлицитну забрану означавања функција, институција које нису суд и интерних позива на чланове. Поједностављени пример улаза и очекиваног излаза гласи:

```
Ulaz: „Ovim zakonom uređuje se rad Ustavnog suda, objavljen u „Službenom glasniku RS“, broj 109/2021.“
Izlaz: [{"text": "Ovim zakonom", "label": "LAW"}, {"text": "Ustavnog suda", "label": "COURT"}, {"text": "Službenom glasniku RS, broj 109/2021", "label": "OFFICIAL_GAZETTE"}]
```

За „мислеће“ варијанте генерисано расуђивање одвајано је од коначног одговора и није улазило у евалуацију. Ради ограничавања трошкова извршавања, дужина излаза „мислећих“ модела била је ограничена, уз пажљиво постављање границе тако да уобичајено расуђивање не буде прекинуто пре коначног JSON одговора.

5.5. Евалуациона метрика

Поређење је извршено на нивоу парова (тип, текст ентитета) по реченици, чиме се избегава зависност од начина токенизације појединачних модела. Рачунате су прецизност, одзив и F1 мера, и то у две варијанте: строга (идентичан текст ентитета) и ублажена (engl. relaxed), у којој се признаје преклапање, односно садржавање једног текста у другом. Ублажена мера праведнија је према разликама у конвенцији одређивања граница ентитета, које се јављају између модела тренираних на различитим доменама.

Прецизност (P) дефинише се као удео тачно препознатих ентитета међу свим ентитетима које је модел предложио, одзив (R) као удео тачно препознатих ентитета међу свим ентитетима у златном стандарду, а F1 мера као њихова хармонијска средина ($F1 = 2 \cdot P \cdot R / (P + R)$). Коришћен је микро-просек, у којем се доприноси свих типова сабирају пре рачунања мере, чиме доминантни типови (LAW и OFFICIAL_GAZETTE) природно више утичу на укупан резултат. Ради избегавања пристрасности при полуаутоматској анотацији, за предобележавање нису коришћени модели који се оцењују, па добијени златни стандард не фаворизује ниједан од испитиваних система.


6. Резултати

У Табели 4 приказани су укупни резултати (микро-просек) за свих пет испитиваних система на заједничком подскупу од 452 реченице, и то према строгој и ублаженој метрици. У Табели 5 приказане су F1 мере по појединачним типовима ентитета (ублажена метрика), а у Табели 6 резултати инструкцијских модела на целом тест скупу.


На заједничком подскупу, најбољи укупни резултат међу генеративним моделима остварује Qwen3-30B у „мислећој“ варијанти ($F1 = 0,328$ строго, $0,353$ ублажено), праћен истом величином у инструкцијској варијанти. Најочљивија разлика није у укупној F1 мери, већ у профилу прецизност–одзив: „мислећи“ модели бележе изузетно високу прецизност ($0,76$ – $0,83$) уз низак одзив ($0,16$ – $0,21$), док инструкцијски модели имају обрнут профил (прецизност око $0,21$, одзив $0,31$ – $0,32$). Специјализовани модел NER4Legal_SRB по строгој метрици остварује најнижи резултат ($0,064$), али по ублаженој достиже $0,364$, што га сврстава међу најбоље — налаз који се детаљно тумачи у наредном поглављу.

Систем	P	R	F1 строго	F1 релаксирано
Qwen3-4B instruct	0,21	0,32	0,255	0,295
Qwen3-4B thinking	0,78	0,16	0,271	0,287
Qwen3-30B instruct	0,21	0,31	0,249	0,333
Qwen3-30B thinking	0,76	0,21	0,328	0,353
NER4Legal_SRB (baseline)	—	—	0,064	0,364

Табела 4. Укупни резултати (подскуп од 452 реченица).




Графикон 1: Табеларни приказ F1 мера по систему



Графикон 2: Табеларни приказ прецизности и одзива по систему (строга метрика)

Тип	4B inst	4B think	30B inst	30B think	NER4Legal
COURT	0,54	0,55	0,45	0,63	0,03
DATE	0,38	0,17	0,63	0,40	0,63
DECISION	0,04	0,07	0,04	0,10	0,00
LAW	0,25	0,36	0,29	0,45	0,16
MONEY	0,34	0,29	0,24	0,29	0,65
OFFICIAL_GAZETTE	0,41	0,21	0,43	0,19	0,55
PERSON	0,05	0,00	0,00	0,00	0,00
REFERENCE	0,08	0,09	0,26	0,33	0,03

Табела 5. F1 мера по типу ентитета (ублажена метрика).



Графикон 3: Табеларни приказ F1 мере по типу ентитета (релаксирана метрика)

Систем	F1 strogo	F1 relaxed
Qwen3-4B instruct	0,448	0,503
Qwen3-30B instruct	0,441	0,575
NER4Legal_SRB	0,061	0,421

Табела 6. Резултати на целом тест скупу (1.375 реченица).

На целом тест скупу инструкцијски модели постижу више вредности него на гушћем подскупу (Табела 6), будући да пун скуп садржи и велики број реченица без ентитета и тиме представља лакши узорак. „Мислећи“ модели нису покретани на целом скупу због приближно стотину пута споријег извршавања. Због тога подскуп од 452 реченице служи као заједничка, тежа основа за фер поређење свих система, док Табела 6 даје допунски увид у понашање инструкцијских модела на целокупном домену.

7. Дискусија резултата

Први резултат односи се на утицај врсте модела. „Мислећа“ варијанта не побољшава значајно укупну F1 меру у односу на инструкцијску, али дрстично мења однос прецизности и одзива: „мислећи“ модели постижу високу прецизност (0,76–0,83) уз низак одзив (0,16–0,21), док су инструкцијски модели уравнотеженији, али бучнији (прецизност око 0,21). Другим речима, експлицитно расуђивање чини модел затворенијим односно наводи га да изостави несигурне кандидате, чиме смањује број лажно позитивних, али повећава број пропуштених ентитета. Овај резултат је у складу са запажањем да расуђивање не доноси корист подједнако на свим задацима [8].

Други резултат тиче се димензије модела. Код инструкцијских модела повећање са 4B на 30B параметара готово да не мења резултат по строгој метрици (0,255 наспрам 0,249), што је сагласно ранијем запажању да величина модела има ограничен утицај на NER [5]. Међутим, код „мислећих“ модела већи модел доноси приметно побољшање (0,271 наспрам 0,328 по строгој метрици). Уочава се, дакле, интеракција врсте и димензије: предности расуђивања долазе до изражаја тек код модела довољног капацитета.

Трећи резултат односи се на специјализовани модел NER4Legal_SRB. Иако на судским пресудама постиже F1 меру од 0,96 [6], на текстовима закона његов учинак драстично опада (0,064 по строгој, 0,364 по ублаженој метрици). Анализа по типовима показује да модел задржава тачност на типовима карактеристичним за пресуде (MONEY 0,65; DATE 0,63; OFFICIAL_GAZETTE 0,55), али подбацује на типу LAW (0,16), који доминира у законима услед честих позива облика „овог закона“. Ово је јасан пример пада услед промене домена: модел научен на једном жанру правног текста слабо се преноси на други. Велика разлика између строге и ублажене метрике додатно показује да се неусклађеност делом своди на различите конвенције одређивања граница ентитета.

Генерално *prompt*овање генеративних модела показује се робуснијим преко домена од специјализованог модела, јер успешно препознаје доминантни тип LAW који специјализовани модел пропушта. Најбољи резултат међу генеративним моделима остварује Qwen3-30B у „мислећој“ варијанти. Ипак, апсолутне вредности F1 мере (до око 0,35 на гушћем подскупу) потврђују полазну хипотезу из литературе [7] да *prompt*овање, без *fine-tuning*a, и даље заостаје за квалитетом који пружају фино подешени модели у оквиру свог домена.

Квалитативна анализа грешака додатно осветљава добијене бројеве. Инструкцијски модели у *zero-shot* и *few-shot* режиму склони су претераном означавању: у одсуству довољно примера, модел неретко додељује ентитете општим појмовима или измишља ознаке ван задате схеме (уочене су, на пример, непостојеће ознаке типа „PARTY“ или „EMPLOYER“ пре поопштравања инструкције). Укључивање експлицитних негативних правила у *prompt* (шта се не означава) и примера знатно је смањило овакве грешке, али их није у потпуности отклонило.

Код „мислећих“ модела доминантан тип грешке је изостављање: модел кроз расуђивање одлучује да несигуран кандидат не значи, чиме расте прецизност, али опада одзив. Код специјализованог модела NER4Legal_SRB типичне грешке су неусклађене границе — на пример, модел препознаје „Службени гласник RS“, док златни стандард обухвата пун навод „Службени гласник RS, број 44/2018“ — што строга метрика кажњава, а ублажена делимично прихвата. Овај образац објашњава велики јаз између строге и ублажене мере код тог модела.

8. Ограничења

Резултате треба тумачити уз неколико ограничења. Прво, расподела ентитета у легислативи је изразито неуравнотежена: типови PERSON, DECISION и REFERENCE јављају се у малом броју примера, па су њихове појединачне F1 мере статистички мање поуздане. Друго, „мислећи“ модели евалуирани су на подскупу од 452 реченице због високе рачунарске цене извршавања, иако тај подскуп обухвата све појаве ретких типова и стога верно одражава њихов учинак на тим типовима. Треће, анотацију је извршио један анотатор, па није мерена сагласност међу анотаторима. Коначно, резултати се

односе на конкретну фамилију модела и конкретну формулацију prompta; другачији prompt или друге фамилије модела могли би дати другачије вредности.

9. Закључак

У раду је испитана применљивост promptovanja великих језичких модела за препознавање именованих ентитета у српској легислативи, без fine-tuninga. Креиран је наменски аотирани скуп података са осам типова правних ентитета и спроведена је упоредна анализа инструкцијских и „мислећих“ варијанти модела Qwen3 у две димензије, уз специјализовани модел NER4Legal_SRB као референцу.

Главни закључци су следећи: (1) „мислећа“ варијанта не повећава укупну F1 меру, већ помера однос ка високој прецизности и ниском одзиву; (2) величина модела слабо утиче на инструкцијске, али приметно побољшава „мислеће“ моделе; (3) специјализовани модел трпи значајан пад услед промене домена, док се promptovanje показује робуснијим; и (4) упркос томе, promptovanje без fine-tuninga и даље заостаје за фино подешеним моделима у њиховом домену.

Из практичног угла, добијени резултати сугеришу да за поуздану аутоматску обраду српске легислативе и даље има смисла улагати у аотирани корпусе и фино подешавање, будући да promptovanje, иако флексибилно и независно од додатног тренирања, не достиже потребан ниво тачности. Ипак, робусност promptovanja кроз различите домене и висока прецизност „мислећих“ модела отварају простор за хибридне приступе, у којима би генеративни модел служио за предлагање кандидата, а специјализовани модел за њихову потврду. Будући рад могао би обухватити већи и уравнотеженији скуп података, ангажовање више аотатора ради мерења међусобне сагласности, испитивање додатних фамилија модела и напреднијих стратегија promptovanja, као и комбиновање генеративних и фино подешених модела.

10. Литература

- [1] A. Vaswani et al., „Attention Is All You Need", Advances in Neural Information Processing Systems (NeurIPS), 2017.
- [2] J. Devlin, M.-W. Chang, K. Lee, K. Toutanova, „BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding", NAACL-HLT, 2019.
- [3] K. Clark, M.-T. Luong, Q. V. Le, C. D. Manning, „ELECTRA: Pre-training Text Encoders as Discriminators Rather Than Generators", ICLR, 2020.
- [4] N. Ljubešić, D. Lauc, „BERTić – The Transformer Language Model for Bosnian, Croatian, Montenegrin and Serbian", Proceedings of the 8th BSNLP Workshop, 2021.
- [5] M. Škorić, „New Language Models for Serbian", Infotheca, vol. 24, no. 1, 2025.
- [6] V. Kalušev, B. Brkljač, „Named Entity Recognition for Serbian Legal Documents: Design, Methodology and Dataset Development", 15. konferencija ICIST, 2025 (arXiv:2502.10582).
- [7] „From Zero to Hero: Building Serbian NER from Rules to LLMs", Radionica R2LM, ACL, 2025.
- [8] T. Kuzman Pungershek et al., „State of the Art in Text Classification for South Slavic Languages: Fine-Tuning or Prompting?", 2025 (arXiv:2511.07989).
- [9] T. Brown et al., „Language Models are Few-Shot Learners" (GPT-3), NeurIPS, 2020.
- [10] J. Wei et al., „Chain-of-Thought Prompting Elicits Reasoning in Large Language Models", NeurIPS, 2022.
- [11] Qwen Team, „Qwen3 Technical Report", Alibaba Group, 2025 (arXiv:2505.09388).
- [12] V. Batanović i dr., „SETimes.SR – A Reference Training Corpus of Serbian", <https://vukbatanovic.github.io/SETimes.SR/>.
- [13] N. Ljubešić i dr., „ReLDI-NormTagNER-sr", CLARIN.SI repozitorijum, <http://hdl.handle.net/11356/1794>.
- [14] „hr500k – Training corpus of Croatian", CLARIN.SI, <http://hdl.handle.net/11356/1792>.
- [15] Društvo za jezičke resurse i tehnologije (Jerteh), „SrpELTeC-gold-NER", Hugging Face, <https://huggingface.co/datasets/jerteh/SrpELTeC-gold-NER> (dataset).
- [16] X. Pan et al., „Cross-lingual Name Tagging and Linking for 282 Languages" (WikiANN/PAN-X), ACL, 2017.
- [17] M. Bogdanović, J. Tošić, N. Petrović, „SrBERTa", Hugging Face, <https://huggingface.co/nemanjaPetrovic/SrBERTa> (model).
- [18] Zakon o autorskom i srodnim pravima, „Službeni glasnik RS", čl. 6. (zakon).
- [19] Pravno-informacioni sistem Republike Srbije, <https://pravno-informacioni-sistem.rs/>.
- [20] <https://www.shaip.com/blog/named-entity-recognition-and-its-types/>

[21] https://www.researchgate.net/figure/llustrative-diagram-of-the-Semantic-Dimension-Model-using-NER-LLM_fig2_393571157